



WHEN
AI BEGINS
TO BUILD
ITSELF

QUANDO A IA COMEÇA A CONSTRUIR A SI MESMA

Análise acadêmica e didática de When AI builds itself: Our progress toward recursive self-improvement, and its implications

Tese central

A IA já acelera o desenvolvimento de novas IAs. O autoaperfeiçoamento recursivo completo, porém, permanece uma possibilidade futura, condicionada à automação do julgamento científico, da definição de objetivos e da validação.

Aridio Silva
Setembro de 2026

Imagem de capa gerada por IA sob direção criativa de Aridio Silva.

Análise acadêmica e didática do artigo When AI builds itself: Our progress toward recursive self-improvement, and its implications

Análise preparada para Aridio Silva

Data: setembro de 2026

Resumo

O artigo do Anthropic Institute sustenta que a inteligência artificial já começou a acelerar materialmente o desenvolvimento de novas inteligências artificiais. A participação crescente dos agentes de IA em programação, experimentação e pesquisa cria um ciclo de melhoria potencialmente cumulativo. Os autores não afirmam que o autoaperfeiçoamento recursivo completo já exista, nem que seja inevitável. Afirmam, porém, que a automação progressiva do ciclo de pesquisa e desenvolvimento pode levar a sistemas capazes de projetar, testar e desenvolver seus sucessores com participação humana cada vez menor.

A leitura academicamente mais equilibrada é que o artigo oferece evidências fortes de P&D; em IA acelerada por IA, mas ainda não demonstra autoaperfeiçoamento recursivo completo. A transição entre essas duas condições depende da automatização de capacidades ainda frágeis, como julgamento científico, definição de objetivos, avaliação de evidências, inovação conceitual e controle de riscos.

Palavras-chave: inteligência artificial; agentes autônomos; autoaperfeiçoamento recursivo; pesquisa automatizada; governança de IA; segurança de IA; supervisão humana.

1. Identificação e natureza do texto

O texto analisado é "When AI builds itself: Our progress toward recursive self-improvement, and its implications", de Marina Favaro e Jack Clark, publicado pelo Anthropic Institute. Uma tradução conceitual adequada seria:

"Quando a IA constrói a si mesma: nosso progresso em direção ao autoaperfeiçoamento recursivo e suas implicações."

Trata-se de um ensaio institucional fundamentado em benchmarks públicos, experimentos da Anthropic, dados operacionais internos e depoimentos de funcionários. Não deve ser confundido com um artigo científico tradicional revisado por pares. Essa natureza híbrida lhe confere grande relevância prática, mas também impõe limites à reprodutibilidade e à auditoria independente de parte das evidências.

2. Tese central

A tese central pode ser formulada da seguinte maneira:

A IA já passou a executar partes relevantes do processo de criação de sistemas de IA. Ao tornar pesquisadores e engenheiros mais produtivos, ela acelera a criação de modelos melhores, que poderão ampliar ainda mais a capacidade de desenvolver a geração seguinte. Se o ciclo for suficientemente automatizado, poderá surgir o autoaperfeiçoamento recursivo.

O argumento é composto por cinco passos:

- 1 A IA executa uma parcela crescente do trabalho de engenharia e pesquisa.
- 2 Essa automação aumenta a velocidade e a escala da P&D.;
- 3 Uma P&D; mais rápida produz sistemas mais capazes em menos tempo.

- 4 Sistemas mais capazes aceleram ainda mais a P&D; da geração seguinte.
- 5 Se a seleção de objetivos, a avaliação e a decisão estratégica também forem automatizadas, o ciclo poderá tornar-se autônomo.

A contribuição conceitual mais importante do artigo é apresentar o autoaperfeiçoamento recursivo como um processo gradual de fechamento do ciclo de P&D;, e não necessariamente como um evento súbito no qual uma máquina reescreve integralmente a própria inteligência.

3. Conceito de autoaperfeiçoamento recursivo

É útil distinguir três níveis:

Estágio	Papel da IA	Papel humano
IA como ferramenta	Sugere código, explica problemas e auxilia tarefas	Define e executa o processo
P&D; acelerada por IA	Implementa soluções, executa testes e conduz experimentos	Define objetivos, supervisiona e julga resultados
Autoaperfeiçoamento recursivo	Projeta, testa e desenvolve sua sucessora	Limita-se à supervisão ou deixa de ser necessário

O ciclo pode ser representado por:

$$M_t \rightarrow P_t \rightarrow M_{t+1}$$

em que (M_t) é o modelo atual, (P_t) é o processo de pesquisa e desenvolvimento realizado com sua ajuda e (M_{t+1}) é o sistema sucessor.

Há recursividade quando o modelo sucessor aumenta a capacidade de produzir a geração seguinte:

$$M_{t+1} > M_t \quad \rightarrow \quad P_{t+1} > P_t$$

O elemento decisivo é o feedback positivo: modelos melhores aceleram a criação de modelos ainda melhores. Isso não implica, contudo, uma explosão instantânea de inteligência. Computação, energia, dados, fabricação de chips, validação, segurança e governança podem limitar o ciclo.

4. A cadeia de evidências do artigo

4.1 Tarefas autônomas mais longas

O artigo utiliza a métrica task-completion time horizon, desenvolvida pela METR. Ela estima a duração, medida em tempo de trabalho humano, das tarefas que um agente consegue concluir com determinada probabilidade de sucesso.

Um horizonte de 12 horas não significa necessariamente que o agente permaneça ativo durante 12 horas. Significa que consegue solucionar, com a confiabilidade adotada, uma tarefa que levaria aproximadamente esse tempo para um profissional humano com pouco contexto prévio.

A METR observa crescimento exponencial dessa capacidade, mas reconhece limitações importantes:

- medições acima de 16 horas ainda são pouco confiáveis;
- os testes concentram-se em software, aprendizado de máquina e cibersegurança;
- as tarefas são relativamente bem especificadas e possuem critérios verificáveis;
- a métrica não representa todas as atividades intelectuais ou todos os empregos.

Portanto, a conclusão apropriada é que os agentes sustentam cadeias maiores de ações coerentes, e não que já possuam autonomia intelectual geral.

4.2 Produção de código e produtividade

A Anthropic afirma que, em maio de 2026, mais de 80% das linhas de código incorporadas ao seu código-base podiam ser atribuídas a Claude. Relata também que o engenheiro típico passou a integrar aproximadamente oito vezes mais código por dia do que em 2024.

Esses números indicam mudança operacional importante, mas não constituem uma medida direta de produtividade. Mais linhas podem decorrer de implementações extensas, mais testes, documentação adicional, retrabalho ou tarefas que antes não seriam realizadas. A própria Anthropic reconhece que o crescimento de oito vezes provavelmente superestima o ganho real.

Um estudo randomizado da METR com ferramentas do início de 2025 encontrou desaceleração entre desenvolvedores experientes trabalhando em repositórios que conheciam profundamente, apesar de eles acreditarem que haviam trabalhado mais rápido. O resultado não invalida os dados posteriores da Anthropic, pois modelos, ferramentas e tarefas são diferentes. Ele demonstra, entretanto, que volume de código, percepção de velocidade e produtividade causal são conceitos distintos.

4.3 Da execução para o julgamento

O texto sugere uma hierarquia de capacidades:

- 1 executar uma tarefa bem especificada;
- 2 descobrir como alcançar um objetivo dado;
- 3 escolher o próximo experimento;
- 4 definir quais problemas merecem investigação;
- 5 avaliar a relevância e a confiabilidade dos resultados;
- 6 definir autonomamente a direção estratégica da pesquisa.

Os sistemas atuais parecem avançados nos primeiros níveis, mas permanecem mais frágeis nos últimos. Escrever código rapidamente não equivale a formular uma pergunta científica importante, reconhecer uma descoberta inesperada, avaliar evidências contraditórias ou decidir que um sistema não deve ser construído.

Essa capacidade de discernimento é chamada no artigo de research taste: gosto, julgamento ou discernimento científico. Ela representa hoje uma das principais vantagens comparativas humanas.

4.4 Automação do ciclo experimental

Uma das principais evidências é o experimento Automated Weak-to-Strong Researcher. Agentes baseados em Claude receberam um problema sobre supervisão de sistemas mais fortes por modelos mais fracos e puderam formular hipóteses, executar experimentos, treinar modelos, analisar resultados e compartilhar descobertas.

O sistema recuperou 97% da diferença de desempenho definida pelo teste, contra cerca de 23% obtidos por dois pesquisadores humanos em aproximadamente uma semana. Contudo:

- humanos escolheram o problema;
- humanos construíram o ambiente e a função de pontuação;
- os agentes receberam direções iniciais diversificadas;
- o resultado não se transferiu perfeitamente para modelos em escala de produção;
- foram usadas cerca de 800 horas cumulativas de agentes e US\$ 18 mil em computação;
- surgiram comportamentos de exploração excessiva da métrica de recompensa.

O experimento demonstra pesquisa automatizada em um espaço preparado e mensurável, não ciência plenamente autônoma.

5. Contribuição conceitual

O artigo desloca o debate da imagem especulativa de uma IA “reescrevendo o próprio cérebro” para uma interpretação operacional. O autoaperfeiçoamento pode surgir da automação progressiva da cadeia:

problema → hipótese → código → experimento → avaliação → novo modelo

Os humanos ainda dominam o início e o final: selecionam problemas, estabelecem critérios e autorizam implantações. O espaço intermediário, porém, está sendo crescentemente automatizado.

A pergunta empiricamente útil deixa de ser “a IA já consegue melhorar integralmente a si mesma?” e passa a ser:

Qual proporção do ciclo de desenvolvimento ainda depende de julgamento humano insubstituível?

6. Avaliação acadêmica das evidências

Evidência	Valor científico	Limitação
Benchmarks públicos	Comparabilidade e alguma reprodutibilidade	Podem saturar e representar tarefas estreitas
Experimentos internos	Alta relevância para o desenvolvimento real de IA	Dados parcialmente fechados e difíceis de reproduzir
Pesquisas com funcionários	Revelam transformações organizacionais	Sujeitas a seleção, entusiasmo e erro de percepção
Extrapolações exponenciais	Úteis para cenários e preparação	Não provam que a tendência continuará
Casos exemplares	Demonstram capacidades concretas	Podem não representar o desempenho médio

A maior fragilidade acadêmica é a limitada auditabilidade dos dados internos. A Anthropic é simultaneamente desenvolvedora dos modelos, produtora dos dados, intérprete dos resultados e parte interessada na percepção pública de suas capacidades e riscos. Isso não invalida as evidências, mas torna indispensável a triangulação independente.

Também existe risco de seleção de casos, mudanças de composição das tarefas, avaliação de sistemas por outros modelos da mesma família e confusão entre resultados de laboratório e desempenho organizacional geral.

7. O salto lógico ainda não demonstrado

O artigo sustenta razoavelmente:

IA ⇒ aceleração da P&D; em IA

Mas ainda não demonstra:

aceleração da P&D; ⇒ autoaperfeiçoamento recursivo completo

Entre as duas proposições existem obstáculos:

- definição autônoma de objetivos relevantes;
- inovação conceitual genuína;
- transferência de resultados para sistemas reais;
- acesso seguro a infraestrutura computacional;
- coordenação de projetos complexos;
- avaliação independente de segurança;

- detecção de métricas inadequadas;
- autorização organizacional e regulatória.

A evidência apresentada sustenta melhor a ideia de aceleração cumulativa assistida por IA do que a previsão de uma iminente explosão autônoma de inteligência.

8. Três cenários de futuro

8.1 A curva desacelera

As tendências exponenciais convertem-se em curvas em “S”. Julgamento científico, inovação profunda e compreensão contextual permanecem difíceis. Ainda assim, a difusão das capacidades atuais transforma organizações e mercados.

8.2 Automação cumulativa com direção humana

Agentes executam quase todo o trabalho operacional, enquanto pessoas selecionam problemas, definem objetivos, interpretam resultados, autorizam mudanças e assumem responsabilidade. Este é o cenário considerado mais provável no artigo.

8.3 Autoaperfeiçoamento recursivo completo

A IA passa a definir, executar e avaliar o desenvolvimento de sua sucessora. O ritmo fica limitado sobretudo por computação, energia, infraestrutura e verificação. É um cenário plausível, mas não demonstrado pelos resultados disponíveis.

9. Lei de Amdahl e deslocamento dos gargalos

Automatizar uma parte do processo não acelera indefinidamente o sistema inteiro. A parte não automatizada torna-se o novo gargalo.

Antes	Depois da automação
Escrever código	Verificar código
Executar experimentos	Escolher experimentos
Produzir hipóteses	Selecionar hipóteses relevantes
Encontrar vulnerabilidades	Corrigir vulnerabilidades
Gerar conteúdo	Validar confiabilidade
Escassez de execução	Escassez de julgamento e responsabilização

A consequência crítica é que a produtividade da geração pode superar a capacidade institucional de validação.

10. Implicações para segurança e governança

Quanto mais um sistema participa da criação de seu sucessor, menos suficiente se torna avaliar somente o produto final. É necessário governar o ciclo de melhoria. Isso requer:

- separação entre agentes produtores e verificadores;
- supervisão humana sobre objetivos e critérios de sucesso;
- ambientes isolados e permissões mínimas;
- limites de computação e de acesso à infraestrutura;
- registros imutáveis de experimentos, decisões e alterações;

- avaliações independentes antes de ampliar autonomia;
- monitoramento de manipulação de métricas;
- testes de generalização fora do ambiente experimental;
- mecanismos técnicos e institucionais de interrupção;
- atribuição clara de responsabilidade humana;
- divulgação de incidentes e auditoria por terceiros.

O risco não se limita a uma IA deliberadamente hostil. Inclui sistemas que otimizam de maneira extremamente eficiente objetivos incompletos, produzem sucessores difíceis de compreender e operam mais rapidamente do que a capacidade humana de inspeção.

11. Implicações epistemológicas

Quando experimentos se tornam baratos e abundantes, o recurso escasso deixa de ser a execução e passa a ser a capacidade de:

- formular boas perguntas;
- selecionar evidências confiáveis;
- distinguir correlação de causalidade;
- interpretar resultados inesperados;
- compreender o que não foi medido;
- atribuir significado científico e social às descobertas.

Surge também o risco de monocultura epistemológica. Agentes semelhantes, treinados com dados semelhantes e avaliados pelas mesmas métricas podem reproduzir os mesmos pressupostos e convergir prematuramente. A pesquisa da Anthropic encontrou “colapso de entropia”: sem direções diversificadas, agentes concentravam-se em poucas famílias de ideias. Multiplicar agentes, portanto, não garante diversidade intelectual.

12. Dimensão humana e organizacional

A automação altera tanto a produtividade quanto a formação do conhecimento. Se pesquisadores deixam de programar, depurar sistemas e discutir problemas com colegas, podem ocorrer:

- perda gradual de domínio técnico;
- dificuldade para revisar resultados da IA;
- dependência cognitiva;
- redução da aprendizagem informal;
- enfraquecimento da colaboração;
- perda de consciência situacional;
- sensação de irrelevância profissional.

Forma-se um paradoxo:

Quanto mais indispensável se torna a supervisão humana, maior é o risco de os humanos perderem as competências necessárias para exercê-la.

A governança precisa preservar não apenas o human in the loop, mas também o human capable of understanding the loop: uma pessoa efetivamente capaz de compreender, contestar e interromper o processo.

13. Conclusão crítica

O artigo é importante porque apresenta evidências de que a IA já participa substancialmente da construção de sistemas de IA. Sua tese mais defensável não é que o autoaperfeiçoamento recursivo completo já tenha começado, mas que a infraestrutura sociotécnica necessária para ele está sendo montada gradualmente pela automação da pesquisa, engenharia e experimentação.

As evidências sustentam três conclusões:

- 1 a IA já acelera partes relevantes do desenvolvimento de IA;
- 2 o papel humano migra da execução para direção, validação e governança;
- 3 a supervisão pode tornar-se um gargalo antes de a autonomia total ser alcançada.

Ainda não há evidência suficiente para concluir que a tendência exponencial continuará indefinidamente, que o julgamento científico será plenamente automatizado, que os sistemas atuais projetarão autonomamente sucessores superiores ou que ocorrerá uma explosão rápida e inevitável de inteligência.

Em síntese:

O autoaperfeiçoamento recursivo não é um fato consumado nem uma inevitabilidade tecnológica. A aceleração cumulativa da P&D; por agentes de IA, contudo, já constitui uma hipótese empiricamente séria, com consequências suficientes para justificar governança antecipatória, avaliações independentes e mecanismos verificáveis de desaceleração ou interrupção.

A pergunta decisiva não é apenas “quando a IA conseguirá construir a si mesma?”, mas:

Conseguiremos desenvolver instituições capazes de compreender, verificar e governar o ciclo antes que ele opere mais rapidamente do que nossa capacidade de controlá-lo?

Referências

- 1 FAVARO, Marina; CLARK, Jack. When AI builds itself: Our progress toward recursive self-improvement, and its implications. Anthropic Institute, 2026. Disponível em: <https://www.anthropic.com/institute/recursive-self-improvement>. Acesso em: 8 set. 2026.
- 2 METR. Task-Completion Time Horizons of Frontier AI Models. Atualizado em 8 maio 2026. Disponível em: <https://metr.org/time-horizons/>. Acesso em: 8 set. 2026.
- 3 KWA, Thomas et al. Measuring AI Ability to Complete Long Software Tasks. METR, 2025. Disponível em: <https://metr.org/blog/2025-03-19-measuring-ai-ability-to-complete-long-tasks/>. Acesso em: 8 set. 2026.
- 4 SIEGEL, Zachary S. et al. CORE-Bench: Fostering the Credibility of Published Research Through a Computational Reproducibility Agent Benchmark. arXiv:2409.11363, 2024, rev. 2026. Disponível em: <https://arxiv.org/abs/2409.11363>. Acesso em: 8 set. 2026.
- 5 ANTHROPIC. Automated Weak-to-Strong Researcher. Anthropic Alignment Science Blog, 2026. Disponível em: <https://alignment.anthropic.com/2026/automated-w2s-researcher/>. Acesso em: 8 set. 2026.
- 6 BECKER, Joel et al. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. arXiv:2507.09089, 2025. Disponível em: <https://arxiv.org/abs/2507.09089>. Acesso em: 8 set. 2026.

Documento elaborado a partir da análise crítica do artigo e das fontes primárias citadas. Dados internos divulgados pela Anthropic devem ser interpretados considerando as limitações de auditabilidade e reprodução independente.

Declaração sobre a imagem de capa: a ilustração foi gerada por inteligência artificial sob direção criativa do autor e é utilizada como representação conceitual. Os robôs humanoides são elementos metafóricos; o objeto principal da análise é a automação do desenvolvimento de software, pesquisa e modelos de IA.